

Validação cruzada final — as 2 auditorias brutas + V2 + código + literatura

Cruzei as duas auditorias externas originais (a de "árvore", 19 pontos + árvore revisada; a de "Portfolio Manager/Lead Quant", 5 FALHAS + árvore revisada) contra a V2 que vocês já tinham, contra leitura direta de código adicional, e contra pesquisa de literatura feita por 4 agentes em paralelo (BOCPD/Adams & MacKay, Jump Model/ λ , microestrutura de dollar bars, block-bootstrap/multi-resolution/DSR). Resultado: a V2 estava certa em quase tudo que já cobria; o valor novo está em **resolver as duas discordâncias diretas entre as auditorias brutas** (nenhuma delas concordava entre si em 2 pontos centrais) e em **7 gaps reais que nenhuma das 3 auditorias tinha identificado**, confirmados por leitura de código.

As duas discordâncias resolvidas

BOCPD "fit único" — auditoria 1 disse "ok, só troque o nome"; auditoria 2 disse "é a maior falha, precisa reiniciar por fold". A 2ª está errada, refutada com evidência forte.

Reli `run_bocpd (src/regime/bocpd.py:188-218)`: o laço é estritamente sequencial, cada iteração t só consome `obs[t]` + o estado carregado de $t-1$. Não há nenhum passo de otimização em lote. Isso bate exatamente com a Eq. 3 do paper original (Adams & MacKay 2007, arXiv:0710.3742) — $P(r_t | x_{1:t})$ é, por definição matemática do método, uma *filtering distribution* (nunca smoothing) — mesma categoria formal do Kalman filter, onde é consenso que um filtro online não precisa ser "refeito" porque seu estado já é a estatística suficiente de todo o passado causal (Särkkä, *Bayesian Filtering and Smoothing*). Rodar uma vez sobre 2019-2026 e fatiar por fold produz, matematicamente, o mesmo resultado em cada t que reiniciar do zero no início de cada fold. O erro do auditor 2 foi generalizar "precisa refit por fold" do HMM/Jump Model (que usam EM/otimização em lote — aí sim, expandir a janela contaminaria) para o BOCPD, que usa atualização conjugada fechada, sem batch. Pior: **a "correção" proposta reintroduziria uma patologia que o projeto já documentou e corrigiu** — reiniciar o prior a cada fold reproduz o "488 segmentos espúrios numa série estacionária de 500 barras" que motivou a calibração atual do warmup (`bocpd.py:130-146`).

Achado colateral valioso: a auditoria 1 (ponto 4) já tinha alertado, antes da auditoria 2 existir, que chamar isso de "fit" (em vez de "online update") "pode não causar erro agora, mas evita um erro futuro" — e foi exatamente essa confusão terminológica que produziu a "maior falha" da auditoria 2. Ponto validado retroativamente: **vale a pena fazer a troca de nomenclatura na árvore/docs**, é barato e já provou prevenir um erro de leitura real.

Nuance que sobrevive (não é rejeitada): `hazard_lambda` foi calibrado 1x sobre o histórico completo 2019-2026 (que inclui as janelas de teste) — isso é um problema **diferente e real** (já era o P5/N do V2), e a pesquisa de literatura reforça isso: nem a prática original de Adams & MacKay (valores fixos a priori) nem a extensão que aprende o hazard do dado (Turner et al. 2009, mantém-se estritamente sequencial) sustentam calibrar sobre histórico com teste embutido. Isso eleva a prioridade do teste de sensibilidade já recomendado no V2 (P5-i/ii).

Jump Model λ — auditoria 1 propôs testar transferibilidade (λ_{BTC} vs pooled vs por-ativo); auditoria 2 propôs BIC dinâmico por fold e defender a saturação como "honestidade do modelo". A literatura favorece claramente a auditoria 1.

Achei um paper (arXiv:2406.09578, "Dynamic Asset Allocation with Asset-Specific Regime Forecasts") que é quase um espelho do problema do projeto: alerta explicitamente contra "usar um mercado representativo tipo US LargeCap para representar toda a classe de ativos" — BTC fazendo exatamente esse papel para ETH/SOL/BNB/XRP. Calibração por ativo é a norma na literatura de jump models (Nystrup, Bemporad, Cortese, Shu/Kolm/Mulvey — nenhum transplanta λ sem reteste). BIC dinâmico por fold não tem precedente direto (é uma extrapolação combinando duas práticas separadas), e quando BIC foi comparado formalmente nesse exato tipo de modelo (Cortese et al. 2024), **perdeu para FTIC**. A tese "colapso = modelo sendo honesto" não é citada por nenhum paper de jump models revisado, e mesmo o apoio indireto (literatura geral de changepoint) exige uma pré-condição — recalibração local do critério — que o setup atual não satisfaz. Veredito: rodar o experimento de transferibilidade da auditoria 1 primeiro; só depois, se a saturação persistir com λ localmente otimizado, a leitura "ausência real de regime" ganha sustentação.

Gaps reais confirmados por código, que nenhuma das 3 auditorias tinha (ou tinha errado)

- **A "distribuição condicional de retornos futuros" que a auditoria 2 pede como mudança nova (FALHA 2) já existe.** `_anova_or_degenerate(labels, forward_return)` (`m4_regime_comparison.py:548-614`) já testa exatamente isso — Welch's $F + \omega^2$ sobre `forward_return` por bucket de regime — e Welch é uma escolha até mais bem justificada que o Kruskal-Wallis sugerido (robusto à heterocedasticidade que regimes de vol violam por construção, motivo já documentado no código). O gap real não é "criar o teste", é: (a) só existe em $h=1$ barra à frente, nunca $h=5/h=20$; (b) só testa separação de **retorno**, nunca de **volatilidade futura** — apesar do regime ser construído com `log_return_1` e `realized_vol_short`, só metade é validada. Isso também fecha uma preocupação legítima da auditoria 1 (ponto 3, circularidade) que nenhuma auditoria conectou ao código real.
- **"BTC conditional response" (auditoria 1, ponto 7) está genuinamente ausente.** Confirmei em `run_q3_common_factor_regime` (`m4_regime_comparison.py:1472-1604`) que Q3 testa só concordância de RÓTULO (`adjusted_rand`) — nunca $E[r_{\text{asset},t+h} | \text{BTC_regime}_t]$ sobre retorno bruto. O M6 (`m6_common_factor_hypothesis.py`) testa heterogeneidade de EDGE de trade entre símbolos, não isso. É uma pergunta genuinamente diferente das duas já respondidas, e barata de adicionar (reusa o mesmo `as-of` join causal já corrigido).
- **Estatística observada ponderada por trade, não por episódio** (auditoria 1, ponto 8) — confirmei que a NULA já é episódio-aware (AG-092), mas `_q_statistic_from_bucket_codes` ainda pondera a estatística OBSERVADA por contagem de trade. Sensibilidade válida a checar (episódio com 50 trades não deveria pesar 50x mais que um com 1).
- **regime_persistence não tem occupancy por estado, taxa de falso-transição nem delay de detecção** — confirmei em `regime_utility.py` que só existem `median_durationBars/switch_rate/n_segments`. Os pontos 6, 11 e 12 da auditoria 1 (K efetivo, transition failure rate, detection delay) são reais, nada disso existe hoje.
- **Block permutation por episódio (não bootstrap) está correto** — a pesquisa de literatura (Winkler et al. 2015/2016, "multi-level block permutation") confirma que preservar duração/ordem do episódio e permutar o rótulo do bloco inteiro é desenho válido para a pergunta que o projeto faz (bucket carrega informação além da dependência temporal?); bootstrap em bloco resolve um problema diferente (IC de uma métrica). A sugestão da auditoria 1 (ponto 9) não é errada, só desnecessária — o desenho atual já é o método certo para essa pergunta.
- **Microestrutura (auditoria 2, FALHA 4) é factualmente correta mas incompleta.** `count/taker_buy_volume/taker_buy_quote_volume` já existem na dollar bar persistida (`src/data/bars.py:125-179`); a matriz de observação do regime (`_input_obs`, `m4_regime_comparison.py:374-395`) de fato só usa close — mas isso é decisão de desenho documentada (isolar o teste de ortogonalidade dos classificadores), não descuido. Achado mais interessante: `D06f_taker_imbalance_z_48` já é feature T1 **em produção** e não é usada em regime nenhum. VWAP diff e tick-count já existem como candidatas T2 nunca testadas por poder preditivo. E a literatura de VPIN/toxicidade de fluxo (que sustentaria tick-count como proxy de regime) é uma área **contestada academicamente** (Andersen & Bondarenko 2014 vs. autores originais), não um consenso — qualquer adoção precisa de medição própria, não é upgrade automático.
- **Hierarquia multi-resolução tem apoio real na literatura recente (2025-2026)**, mais forte do que eu esperava — "Adaptive Hierarchical HMM for Structural Market Change" (JRFM 2025) e um framework triplo-timeframe explícito (arXiv 2606.06190) sustentam a proposta mais agressiva da auditoria 2 (R3 condicionando R1/R2), não só a versão diagnóstica mais leve da auditoria 1. Mas é fronteira ativa (nenhuma fonte ainda consolidada/muito citada) — dá pra tratar como Estudo 2 com base real, não como capricho de auditor.

Lista final categorizada

REDESENHO (muda arquitetura/lógica existente — Estudo 2, não agora)

Item	Origem	Por quê
Hierarquia real R3→R1/R2 (regime lento como feature condicionante do modelo rápido)	auditoria 2 FALHA3	Literatura real dá suporte, mas exige reordenar computação entre resoluções e criar dependência nova — mudança estrutural genuína
BOCPD/HMM/JM com features de microestrutura nativas (VWAP-por-barra persistido, tick-imbalance bars, D11f/D13f trade-level)	auditoria 2 FALHA4	Engenharia de dado nova (trade-a-trade sobre bilhões de linhas), já adiada antes por custo — não é extensão barata
Multi-resolution R1/R2/R3 como estudo formal pré-registrado	V2 P11	Já era esse o sequenciamento acordado

FIX MECÂNICO (extensão limitada, reusa infraestrutura já existente)

Item	Origem
Separação de retorno futuro em múltiplos horizontes ($h=5/h=20$, hoje só $h=1$)	auditoria 2 FALHA2 (gap real)
Separação de volatilidade futura (só retorno é testado hoje)	achado direto (fecha circularidade da auditoria 1 pt3)
Teste "BTC conditional response" ($E[r_{\text{asset}} \text{BTC_regime}]$, distinto de concordância de rótulo)	auditoria 1 pt7
Estatística observada agregada por episódio, não só por trade (sensibilidade)	auditoria 1 pt8
effective_number_of_states/occupancy por estado	auditoria 1 pt6
Transition failure rate ($N=3/5/10$)	auditoria 1 pt11
Detection delay vs. eventos econômicos independentes	auditoria 1 pt12
Coerência cross-resolution + matriz lead/lag (versão diagnóstica, sem redesenhar o pipeline)	auditoria 1 pt2/10
Recalibração de hazard_lambda restrita a dado pré-janela-de-teste + sensibilidade no grid não-patológico	V2 P5(i)/(ii), reforçado pela literatura
Experimento de transferibilidade de λ do Jump Model (BTC vs pooled vs por-resolução vs por-ativo)	auditoria 1 pt5, favorecido pela literatura sobre BIC dinâmico
Renomear "fit único" → framing explícito de "online update" na árvore/docs	auditoria 1 pt4 (validado — preveniu exatamente o erro da auditoria 2)
Aggregação: reportar median+IQR+%ativos positivos/significativos, não só ponto médio	auditoria 1 pt14/15
p-valor ajustado por múltiplos testes (FDR/BH) + contagem de decisões testadas	auditoria 1 pt16
Tabela mestre com information_cutoff_timestamp por linha	auditoria 1 pt21

Item	Origem
Decisão em 3 estados (VALIDATED/CONDITIONALLY USEFUL/NO EVIDENCE)	V2 P12

HABILITAÇÃO (mecanismo já existe e já é correto — só falta rodar, expor na decisão, ou aplicar padrão já usado em outro lugar)

Item	Origem
Excluir Jump Model do Estudo 1 (reusa o padrão já existente de isolar/logar candidato degenerado, AG-019)	V2 N3
Wiring experimental de D06f (já T1)/D08f/D09f (já T2, nunca testadas) na matriz de observação do regime, medindo IC antes de promover	auditoria 2 FALHA4 (parcial)
Congelar metodologia + locked holdout (a infraestrutura de walk-forward já existe; falta a decisão/disciplina de reservar e nunca tocar)	auditoria 1 pt17/18, V2 P3
Reconciliar N_lifetime com estimativa conservadora (superestimar, nunca subestimar — logicamente correto dado que DSR é monótono crescente em N)	V2 N2, confirmado pela literatura (nenhuma alternativa melhor sem matriz completa de trials)

REJEITADO

Item	Origem	Motivo
BOCPD deve reiniciar do zero a cada fold	auditoria 2 FALHA1	Refutado matematicamente (Eq. 3 Adams & MacKay, filtering ≠ smoothing) + reintroduziria patologia já corrigida
Trocar block permutation por episódio para block bootstrap	auditoria 1 pt9	Literatura confirma que permutação por bloco já é o método certo para essa hipótese específica; bootstrap responde outra pergunta
BIC dinâmico por fold para o Jump Model, como proposta primária	auditoria 2 FALHA5	Sem precedente direto; BIC perdeu para FTIC no mesmo framework quando testado formalmente
"Colapso em 1 estado = modelo sendo honesto", sem investigar mais	auditoria 2 FALHA5	Precondição (recalibração local) não satisfeita hoje — conclusão prematura
Kruskal-Wallis como substituto do Welch's F já em uso	auditoria 2 FALHA2	Welch já é a escolha certa para a mesma heterocedasticidade que motivaria KW; o teste em si (não a fórmula) já existe